SoftwareEngineeringLab1

1. 项目概述

针对需求及特殊情况，本次实现主要功能如下：

- 从文本/GUI 中提取单词，去除非法字符
- 对单词进行预处理，譬如：重复单词自动删除，单词统一转化为小写
- 4 种基本需求
    - 基本需求 1：计算最多单词数量的单词链
    - 基本需求 2：计算字母最多的单词链
    - 基本需求 3：指定单词链开头或结尾字母
    - 基本需求 4：指定单词链的单词个数
- 特殊需求实现
    - -h/-t -c：指定开头或结尾字母的字母数最多的单词链
    - -h/-t -n：指定开头或结尾字母和单词链长度的所有单词链
    - 输入文件为空
    - 输入文件过大时的随机/限制时间搜索
- 异常情况报错
    - 输入异常参数
    - 找不到输入文件位置
- 使用提示信息 Usage:

  Usage 信息函数：

```
void usage(){
    std::string usage="Usage: Wordlist [arguments] <filename>\r\n\
Mandatory arguments:\r\n\
    -c: Output one word list with the most characters. \r\n\
    -w: Output one word list with the most words.\r\n\r\n\
Optional arguments:\r\n\
    -h <char>: Determine the head character of the word list.\r\n\
    -t <char>: Determine the tail character of the word list.\r\n\
    (Note: -h and -t can be used at the same time)\r\n\
    -n <num>: Output all word lists containing <num> words.\r\n\
    (Note: -n must be used with -w)\r\n";
    cout<<usage;
    exit(0);
}
```

  项目实现框架为:

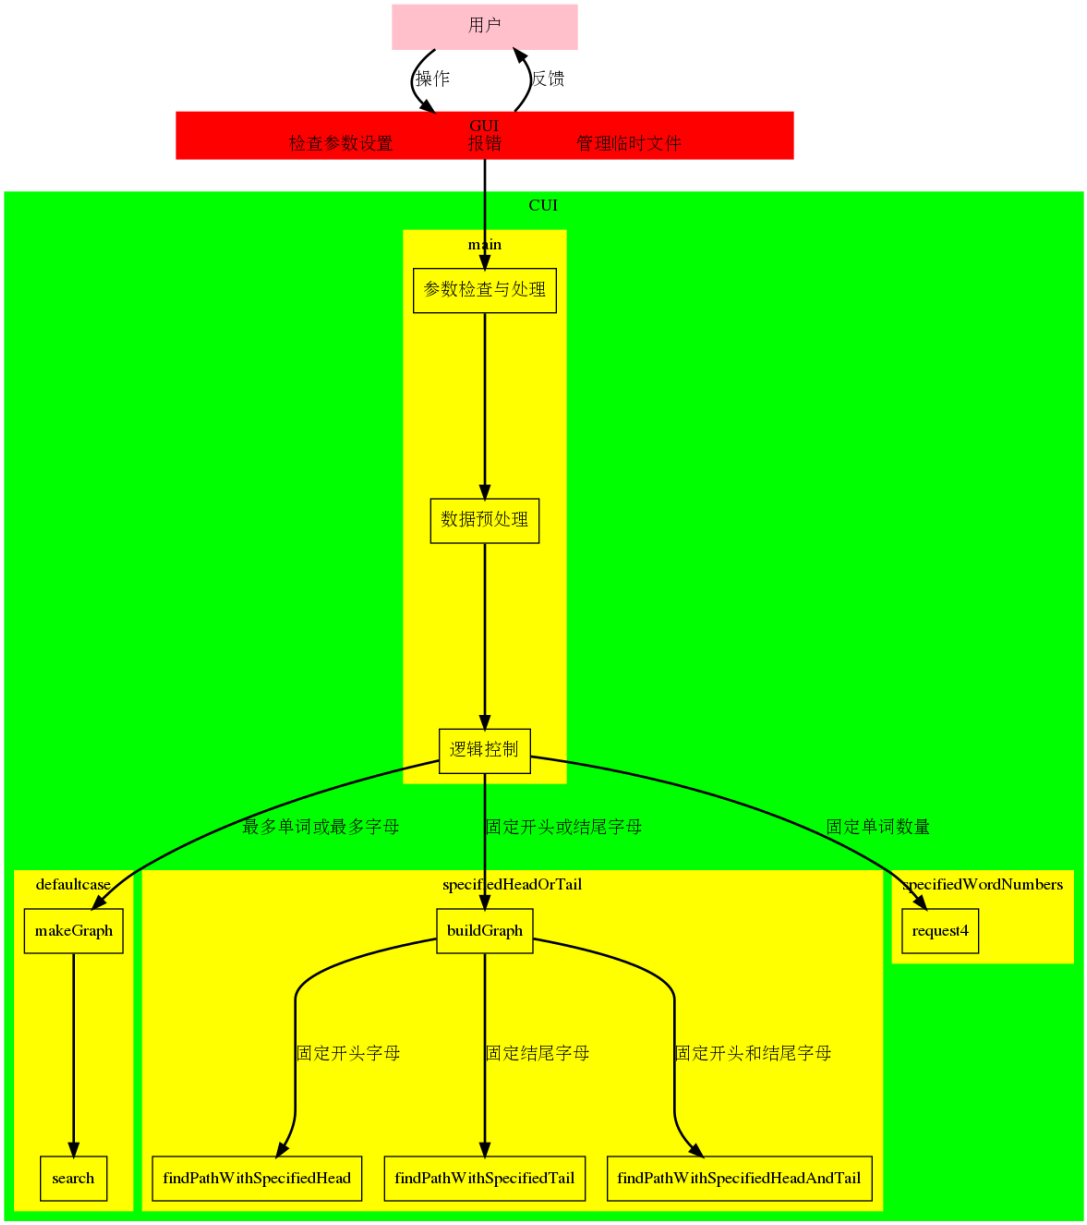

2. 编译环境

- Windows10　gcc 6.3.0
- Ubuntu16.04
- Cpp 标准：c++17
- 具体编译/使用方法请阅读 readme.md

3. GUI 版本使用说明

开发环境

操作系统	Ubuntu 18.10
编译环境	g++ (Ubuntu 8.2.0-7ubuntu1) 8.2.0
图形库	Qt 5.12.0 GCC64bit
设计工具	Qt Creator 4.8.0
依赖库说明	将命令行程序作为依赖库添加在 GUI 目录下重命名为 `WordlistCUI`

界面说明

GUI 控件与命令行版本控件的对应关系：

- 输入区：`QPlainTextEdit InputText`
- 输出区：`QTextBrowser outputText`
- 最多单词数量：`QRadioButton mostWordCheck`
- 最多字母数量：`QRadioButton mostCharCheck`
- 固定开头：`QCheckBox fixHeadCheck`
- 固定开头输入：`QLineEdit fixHead`
- 固定结尾：`QCheckBox fixTailCheck`

- 固定结尾输入：`QLineEdit fixTail`
- 固定单词数量：`QCheckBox fixNumCheck`
- 固定单词数量选择：`QSpinBox fixNumber`
- 搜索单词链：`QPushButton convertButton`
- 从文件加载输入：`QPushButton loadFromFile`
- 将结果导出到文件：`QPushButton saveOutputFile`

槽函数处理

注 ：（这里使用了 Qt 自动关联，on_xxx_clicked() 槽函数自动关联到 xxx 部件信号）

- **处理搜索命令信号：** `void MainWindow::on_convertButton_clicked()`

  创建 `QProcess` 实例准备调用命令行程序 --->

  将输入区文本保存为临时文件 `tempInputFile.txt` --->

  检查各参数对应的部件信号，处理不合法信号组合并给出提示，根据相应的信号设置命令行参数--->

  调用命令行程序--->

  将结果从文件读出并打印在输出文本区

- **处理从文件加载输入信号：** `void MainWindow::on_loadFromFile_clicked()`

  `QFileDialog::getOpenFileName()` 函数获取选择的文件名--->

  读取相应的文件并将内容打印在输入区

- **处理将结果输出到文件信号：** `void MainWindow::on_saveOutputFile_clicked()`

  `QFileDialog::getSaveFileName` 函数获取选择的文件名--->

  新建输出文件将输出区文本写到输出文件

- **处理命令行返回的找不到单词链的信息：** `oid MainWindow::Result(int a)`

  将信号连接到标准输出-->

  CUI 退出值为 1 时提供提示信息

GUI 工作界面

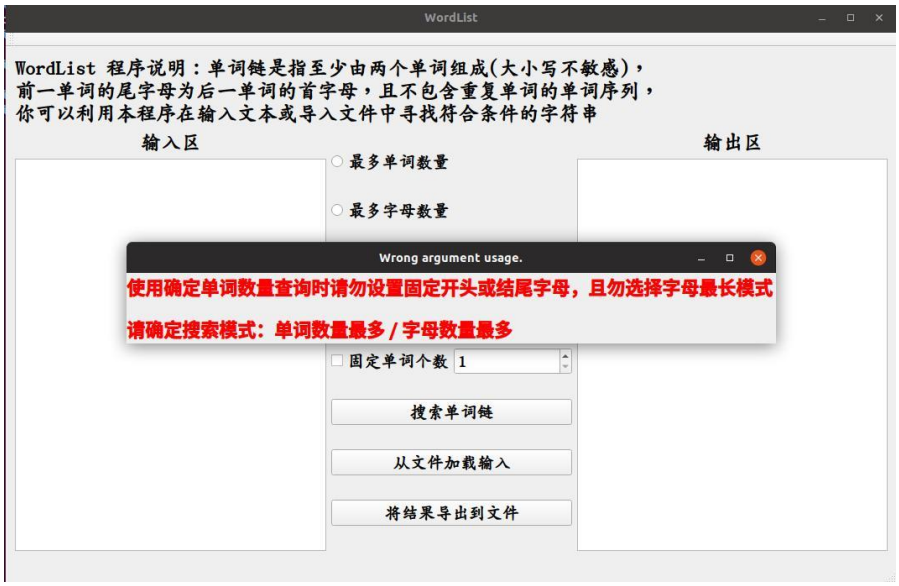
WordList
WordList 程序说明：单词链是指至少由两个单词组成(大小写不敏感)，
前一单词的尾字母为后一单词的首字母，且不包含重复单词的单词序列，
你可以利用本程序在输入文本或导入文件中寻找符合条件的字符串
输入区
输出区
最多单词数量
最多字母数量
Wrong argument usage.
使用确定单词数量查询时请勿设置固定开头或结尾字母，且勿选择字母最长模式
请确定搜索模式：单词数量最多 / 字母数量最多
固定单词个数 1
搜索单词链
从文件加载输入
将结果导出到文件

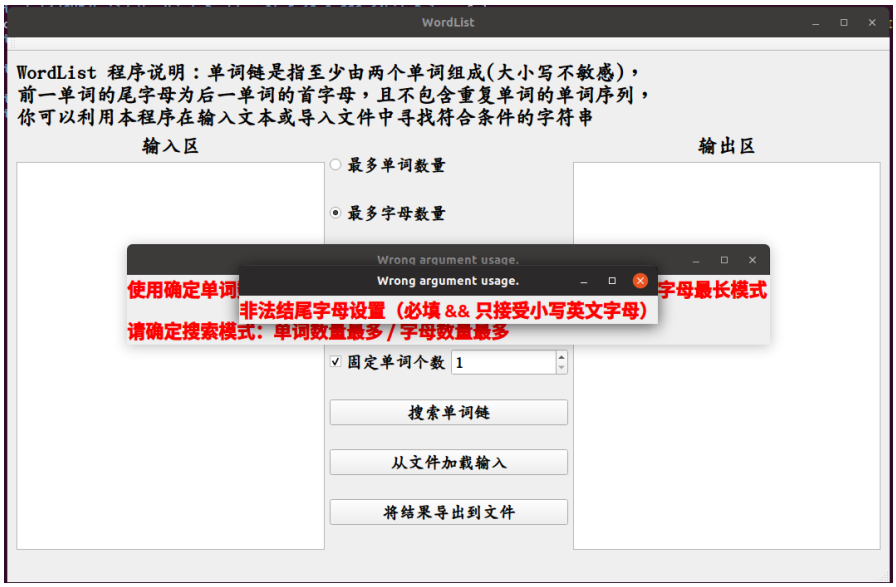
WordList
WordList 程序说明：单词链是指至少由两个单词组成(大小写不敏感)，
前一单词的尾字母为后一单词的首字母，且不包含重复单词的单词序列，
你可以利用本程序在输入文本或导入文件中寻找符合条件的字符串
输入区
输出区
最多单词数量
最多字母数量
Wrong argument usage.
Wrong argument usage.
非法结尾字母设置（必填 && 只接受小写英文字母）
请确定搜索模式：单词数量最多 / 字母数量最多
固定单词个数 1
搜索单词链
从文件加载输入
将结果导出到文件


WordList
WordList 程序说明：单词链是指至少由两个单词组成(大小写不敏感)，
前一单词的尾字母为后一单词的首字母，且不包含重复单词的单词序列，
你可以利用本程序在输入文本或导入文件中寻找符合条件的字符串
输入区
输出区
Algebra
Zoo
Elephant
Under
Dog
Leaf
Pseudopseudohypoparathyroidism
最多单词数量
最多字母数量
No Word List Found.
也许这不是一个错误，但是我确实没有找到符合要求的单词链。
固定单词个数 1
搜索单词链
从文件加载输入
将结果导出到文件

4. 命令行版本主函数设计

- 主函数功能

    - 读取文件
    - **数据预处理：**包括去除不合法字符，大小写转换，去除重复单词。最终提取出的单词存放于 vector<string> crudeData 中，提供给各个函数。
    - **功能分派（dispatch）：**将不同需求分配给不同函数执行
    - **异常报错：**包括异常输入参数，异常文件位置等
    - **输出结果到文件:** 输出到当前目录下的 solution.txt。若不存在则自动创建，已存在则覆盖原文件。

- 主函数控件说明

    为了使得接口更为一致和整洁，工程使用以下功能控制开关和对应变量来实现功能的分派：

    功能控制开关：

```
bool mostChar = false; //最多字母模式开关
bool mostWord = false; //最多单词模式开关
bool fixedWordNum = false; //确定单词数量模式开关
bool fixedHead = false; //确定开头字母模式开关
bool fixedTail = false; //确定结尾字母模式开关
```

    主要变量说明：

```
int wordNum; //确定单词数量模式对应的单词数量
std::string inputFile; //数据文件名
char head,tail; //确定的开头字母和结尾字母
std::string crudeString; //从输入文件读取的原始内容
std::vector<std::string> crudeData = sHoT::preprocessingData(crudeString);
//通过数据预处理得到的字符串向量，作为各功能部件的数据接口输入
```

5. 算法原理

本部分介绍四个需求的实现原理。其中每个需求的文档分为以下部分

- **数据结构：**介绍使用的数据结构和代码实现
- **算法原理：**介绍算法的思想和主要过程
- **核心实现：**介绍算法核心部分的代码实现

其中在需求 4：指定单词个数的单词链中，还加入了算法优化部分的说明。

需求 1:单词数量最多的单词链（位于 defauleCase.h）

- **数据结构：**

有向图，采用邻接链表形式存储。以字母为节点，以单词为边。

实现如下：

```
node *graph[26];// 有向图的邻接链表表示
std::vector<std::string> currentList;// 存储当前的单词链
std::vector<std::string> longestList;// 存储至今最长的单词链
int currentWeight,longestWeight;// 存储当前单词链和最长单词链的总权重
```

节点结构：

```
struct node{
int weight;
bool used;
std::string *data;
struct node *next;
char lastChar;
};
```

节点结构成员的解释：

1)对于边节点：

`weight`：恒为 1（因为不考虑单词长度）

`used`：标记边是否被使用（用于 DFS 防止重复搜索）

`data`：指向一个字符串，存放该边对应的单词

`next`：指向链表中的下一个节点或为 NULL

`lastChar`：该单词的最后一个字母，用于指示该有向边指向的节点。

2)对于头结点：

`next` 指向链表中的下一个节点或为 NULL；其余字段无意义。

- **算法原理**：DFS（Deep First Search)

  DFS 可以得到从一个图节点（字母）出发导出的所有单词链。由于没有指定开头的字母，应当对所有的节点进行深度优先搜索，输出最长的单词链。 在具体使用中，可以使用如下的代码：

```
def::makeGraph(s,0);
def::search();
```

  其中 s 是一个字符串向量 `std::vector<std::string>`,而且每一个单词都应当全部由小写字母组成。最后的结果会输出到与可执行文件同目录的 `solution.txt` 文件中。

- **核心实现**

```
void DFS(node *curr){
  // 深度优先搜索，curr 是一个节点的指针
  node *temp=curr->next;
  //std::cout<<*(temp->data)<<curr->lastChar;
  while(temp!=NULL){
      if (!temp->used){
          temp->used=true;
          currentList.push_back(*(temp->data));
          currentWeight+=temp->weight;
          // 标记使用的边，并在当前单词链中追加单词并增加总权重
          DFS(graph[temp->lastChar-'a']);
```

```
            // 搜索当前边指向的节点
            temp->used=false;
            currentList.pop_back();
            currentWeight-=temp->weight;
            // 回溯，去除标记并在当前单词链中删除单词并减少总权重
        }
        temp=temp->next;
    }
    if (currentWeight>longestWeight){
        //printf("\r\nbegin copy");
        longestList.assign(currentList.begin(),currentList.end());
        longestWeight=currentWeight;
        //printf("\r\nend");
    }
    // 如果当前单词链长于最长的单词链，就进行把当前单词链作为最长单词链
}
```

需求 2:字母最多的单词链（位于 defauleCase.h）

- **数据结构**
  数据结构基本同需求一。
  区别在于：节点权重 `weight` 设置为单词长度而不是 1。

- **算法原理**
  将节点权重 `weight` 设置为单词长度后，算法同需求 1。
  在具体使用中，可以使用如下的代码：

```
def::makeGraph(s,1);
def::search();
```

- **核心实现**

  同需求一。

需求 3:指定开头/结尾字母的单词链（位于 specifiedHeadOrTail.h）

- **数据结构：**

  有向图，使用邻接链表表示，包括字母节点和边节点。

  数据结构实现及解释如下

边节点：

```
struct edge{
    std::string* data;  //边对应的单词
    int weight;         //边的权重，根据模式的不同分别设置为 1 或单词的长度
    char destChar;      //有向边的目的节点
    char originChar;    //有向边的源节点
    bool used;          //使用标志位，避免重复搜索
    struct edge* next;
};
```

点节点：

```
struct node{
    char ch;            //节点对应的字母
    edge* adjEdges;     //邻接链表
};
typedef struct node node;
```

全局变量：

```
std::vector<std::string> searchingPath; //当前搜索路径（单词链）
int searchingWeight;                    //当前搜索路径的权重（长度）
std::vector<std::string> resultPath;    //当前搜索过的最长路径（单词链）
int resultWeight;                       //当前搜索过的最长路径的权重（长
```

- **算法原理：**

  本需求有 3 部分要求：

  - 固定开头字母搜索：DFS
  - 固定结尾字母搜索：DFS。

  其中该方法固定开头字母搜索没有太大区别。在我们的实现中，图结构已按照要求调整，只需要将最后结果反转即可

  - 同时固定开头和结尾字母搜索：DFS。

  区别在于不是在每条路径末尾与最长路径比较，而是当发现到达目标节点时更新最长路径

- **算法实现**

  由于三部分核心搜索相同，因此这里仅展示 `固定开头字母搜索` 的结果：

```
void findPathWithSpecifiedHead(node* graph,char head){
        /*  参数说明：
```

```
                    1、node* graph  要搜索的图
                    2、char head  当前搜索节点
                输出：无输出，将最长路径保存在  resultPath  中
            */
            edge* fromEdge = graph[head - 'a'].adjEdges;
            while(fromEdge != NULL){
                if(fromEdge->used == false){

                    fromEdge->used = true;
                    searchingPath.push_back(*(fromEdge->data));
                    searchingWeight += fromEdge->weight;
                    //DFS 递归搜索
                    findPathWithSpecifiedHead(graph,fromEdge->destChar);

                    searchingWeight -= fromEdge->weight;
                    fromEdge->used = false;
                    searchingPath.pop_back();
                }
                fromEdge = fromEdge->next;
            }
            //每条路径搜索结束后与当前搜索到的最长路径比较，如果更长则更新最长
路径及最长路径权重
            if(searchingWeight > resultWeight){
                resultWeight = searchingWeight;
                resultPath.assign(searchingPath.begin(),searchingPath.end());
            }
        }
```

需求 4:指定单词个数的单词链（位于 specifiedWordNumbers.h）

- **数据结构：**

  有向图，采用邻接表实现。

  图的节点为单词（字符串）。边的定义为：若单词 A 和单词 B 能构成单词链，则 AB 之间存在一条边。

  数据结构实现：`unordered_map<string, vector<string>>`

- **算法原理：动态规划**

  记单词链中单词个数为 n，单词列表长度为 d

  其最优子结构表述为：

n = k 时，所有长度满足要求的单词链存放于 a 中

n = k+1 时，对 a 中每个单词链，在其末尾添加 1 个合法单词。将所有新的单词链存入 a 中

- **算法优化：**
  - 采用 unordered_map（其原理为 hash 表）存储邻接表，节省了查找邻接边的时间
  - 采用 2 个 vector<string>的集合交替存储上一次和当前次的结果，相比于维护动态规划表，极大降低了空间复杂度
  - 对于过大的输入，可以让用户选择随机方式：即采取以一定概率随机裁剪中间结果，从而降低搜索空间。其代价就是不一定能找到所有解，或不一定能找到解。

    目前测试中，对于大数据集 test_4（经过设计的 64 个节点的有向完全图），可以 3 分钟完整输出约 500 万个符合要求的 n=7 时的单词链。具体请参见报告的测试部分。

- **异常情况处理：**

  若输入 n<2，命令行输出错误信息: `error: as defined, word list must have a length at least 2`

  若输入 n>wordlist 长度, 不报错，直接输出 0。

- **算法实现：**

```
//b 的含义：初始化为单词列表
//a 与 b 是交替存储 n=k-1 和 n=k 下所有符合要求的单词链的集合
for(int i=1; i<n; i++){
            a=b;
            b.clear();
            for(vector<string> v : a){//对于长度为 i-1 的所有单词链 v 进行处理
                  string last = v.back();
                  for(string next:adj[last])//尝试所有可连接单词 next
                        if(!used(next, v)){//检查 v 是否已经使用过 next
                              v.push_back(next);
                              b.insert(v);
                              v.pop_back();//向 b 中插入 v+next,并还原 v
                        }
            }
      }
```

特殊情况：大数据集的处理

6. 测试

测试样例设计

本部分介绍了每个测试样例的主要内容和测试功能。列出表格如下:

testcase	设计目的
test_1.txt	基本需求 1，2。该样例为题目中需求 1 给出的测试样例。可测试大小写转化和基本功能
test_2.txt	鲁棒性需求。提供了具有干扰字符的文件。测试程序能否分割输入字符得到单词
test_3.txt	基本需求 3。测试程序是否处理了不同搜索起点的情况，该样例从不同的起点开始得到的搜索结果长度不同
test_4.txt	基本需求 4。大数据集警告：n=64 的合法单词链数目为 5016480，运行时间约为 3 分钟。提供了一幅 64 个顶点的有向完全图，可以测试程序的搜索性能
test_5.txt	基本需求 4。提供了一幅只有两个节点的图，可以测试程序的搜索是否完全，-n 参数输出的路径条数是否正确
test_6.txt	基本需求 3。用于测试-h/-t 分别和-w，-c 共同使用时的输出结果是否相同
test_7.txt	基本需求 4。提供了一个环。测试动态规划能否正确找出所有解。
test_8.txt	鲁棒性需求。提供了具有重复单词的文件。测试程序如何处理错误输入。
test_9.txt	鲁棒性需求。提供了空文件。此为 side case，测试程序的鲁棒性。
test_10.txt	基本需求 4。题目中需求 4 给出的测试样例。

测试结果

本部分列出了每个需求的完成状况。结论为所有需求均完整实现。

鲁棒性需求测试结果

1. **重复单词**：自动去重

   示例：test_8

```
aaa
aaa
aaa
aaa
abb
bacon
```

   `.\Wordlist_win10.exe -w .\test\test_8.txt`

   输出结果：

```
aaa
abb
bacon
```

2. **空文件**：输出文件为空

   示例：test_9(空文件)

   `.\Wordlist_win10.exe -w .\test\test_9.txt`

   输出结果：

   一个空的 solution.txt

3. **干扰字符文件**：自动提取符合要求的字符串

   示例：test_2

```
ab bieiojiosjdfc89biufd.
cd76677667d8---
```

```
dcfaswc/add,daa
```

`.\Wordlist_win10.exe -w .\test\test_2.txt` 输出结果：

```
add

dcfaswc

cd

daa

ab

biufd

d
```

4. **大小写转化**：自动将输入中的大写转化为小写

   示例：test_1

```
Algebra

Apple

Zoo

Elephant

Under

Fox

Dog

Moon

Leaf

Trick

Pseudopseudohypoparathyroidism
```

   `.\Wordlist_win10.exe -w .\test\test_1.txt`

   输出结果：

```
algebra
apple
elephant
trick
```

5. **未规定的参数组合：**报错

```
Wrong argument usage.
```

6. **输入非法参数：**报错

   例如：

   `.\Wordlist_win10.exe -h 2 -w .\test\test_1.txt`

   报错：

```
A character is needed after -h.
```

基本需求 1 测试结果(单词数量最多的单词链)

输入：test_1

```
Algebra
Apple
Zoo
Elephant
Under
Fox
Dog
Moon
Leaf
Trick
```

```
Pseudopseudohypoparathyroidism
```

`.\Wordlist.exe -w .\test\test_1.txt`

输出结果：与正确结果相同

```
algebra

apple

elephant

trick
```

基本需求 2 测试结果(字母数最多的单词链)

输入：test_1

```
Algebra

Apple

Zoo

Elephant

Under

Fox

Dog

Moon

Leaf

Trick

Pseudopseudohypoparathyroidism
```

`.\Wordlist_win10.exe -c .\test\test_1.txt`

输出结果：

```
pseudopseudohypoparathyroidism

moon
```

基本需求 3 测试结果(指定开头或结尾的字母的单词链)

输入：test_1

固定开头为 e

.\Wordlist_win10.exe -h e -w .\test\test_1.txt

```
elephant
trick
```

固定结尾为 t

.\Wordlist_win10.exe -t t -w .\test\test_1.txt

```
algebra
apple
elephant
```

固定开头为 a 和结尾为 t

.\Wordlist_win10.exe -h a -t t -w .\test\test_1.txt

```
algebra
apple
elephant
```

深入测试：特殊需求

-h/-t 与-c 组合的情况

输入：test_6：

```
abcdefgh hijklmn
ab bc cd dn
```

该测试中，规定单词数最多和字母数最多的输出不同

若输入-h/-t -w，则寻找固定开头/结尾的单词数最多的单词链

```
.\Wordlist_win10.exe -h a -t n -w .\test\test_6.txt
```

```
ab

bc

cd

dn
```

若输入-h/-t c，则寻找固定开头/结尾的字母数最多的单词链

```
.\Wordlist_win10.exe -h a -t n -c .\test\test_6.txt
```

```
abcdefgh

hijklmn
```

正确性测试：证明指定的开头字母不同，则输出不同

分别输出字母 a 开头和 w 开头的字符串

输入：test_3.txt

```
ab bc cd de

ef fg gh hi

ij jk kl lm

mn no op pq

qr rs st tu

uv vw wx xy

yz
```

若指定以字母 a 开头：

```
.\Wordlist_win10.exe -h a -w .\test\test_3.txt
```

输出结果：

```
ab
bc
cd
de
ef
fg
gh
hi
ij
jk
kl
lm
mn
no
op
pq
qr
rs
st
tu
uv
vw
wx
xy
```

```
yz
```

若指定以字母 w 开头：

```
.\Wordlist_win10.exe -h w -w .\test\test_3.txt
```

输出结果：

```
wx

xy

yz
```

基本需求 4 测试结果(指定单词链个数的单词链)

基本功能测试

输入：test_10

```
word

digital

list
```

```
.\Wordlist.exe -n 2 -w .\test\test_10.txt
```

输出结果：

```
2

digital

list


word

digital
```

性能测试

由于基本需求 4 为主要性能考察部分，在此设计以下测试考察其性能：

输入：test_4(大数据集)：

7 个节点的有向完全图

```
ab ac ad ae af ag ah
ba bc bd be bf bg bh
ca cb cd ce cf cg ch
da db dc de df dg dh
ea eb ec ed ef eg eh
fa fb fc fd fe fg fh
ga gb gc gd ge gf gh
ha hb hc hd he hf hg
```

`.\Wordlist.exe -n 7 -w .\test\test_4.txt`

测试算法输出所有结果的时间。总共 5016480 个结果，约耗时 3 分钟

输出结果：

```
5016480

ab
ba
ac
ca
ad
da
ae

.....
```

完整性/正确性测试

测试输出的完整性/正确性：测试算法是否能正确输出所有单词链

输入：test_7

所有单词构成一个环

```
abc
cde
efg
ghi
ijk
klm
mna
```

```
.\Wordlist_win10.exe -n 25 -w .\test\test_7.txt
```

输出结果：

```
7

abc

cde

efg

ghi

ijk

klm

mna


cde

efg

ghi

ijk
```

klm

mna

abc

efg

ghi

ijk

klm

mna

abc

cde

ghi

ijk

klm

mna

abc

cde

efg

ijk

klm

mna

abc

cde

efg

```
ghi


klm
mna
abc
cde
efg
ghi
ijk


mna
abc
cde
efg
ghi
ijk
klm
```

可见其正确完整输出所有结果